

数学模型

数学模型引论

CUMCM赛题选讲：碎纸机

谢金星

清华大学数学科学系

Tel: 010-62787812

Email: xiejx@tsinghua.edu.cn

1

2

3

数学模型

“斯塔西”(SATS)档案：解密真相，还原历史

来源：《上海档案》，2014年01期，第29-31页（作者：吴臻）



东德国家安全部徽

1

2

3

数学模型

“斯塔西”(SATS)档案：解密真相，还原历史


来源：《上海档案》，2014年01期，第29-31页（作者：吴臻）



尚未销毁的海量档案包括：

- 159公里长的文件；
- ...

人工拼接进展缓慢；
后来启用计算机辅助



1

2

3

数学模型

[问题]CUMCM-2013B：碎纸片的拼接复原

1. 对于给定的来自同一页印刷文字文件的碎纸机破碎纸片（仅纵切），建立碎纸片拼接复原模型和算法，并针对附件1、附件2给出的中、英文各一页文件的碎片数据进行拼接复原。.....

2. 对于碎纸机既纵切又横切的情形，请设计碎纸片拼接复原模型和算法，并针对附件3、附件4给出的中、英文各一页文件的碎片数据进行拼接复原。...

3. 上述所给碎片数据均为单面打印文件，从现实情形出发，还可能双面打印文件的碎纸片拼接复原问题需要解决。...请尝试设计相应的碎纸片拼接复原模型与算法，并就附件5的碎片数据给出拼接复原结果，...

1

2

3

数学模型

19(纵)

像素：

1980 *

72



1

2

3


数学模型

19(纵)
11(横)

像素：

180 *

72



1

2

3

数学模型

问题分析：特点和难点

人工拼接

通常利用碎片大小和颜色、笔迹和墨水等特征

手撕碎片的复原

碎片一般不规则，还可以利用轮廓信息（边缘形状的几何特征），此类研究文献较多

本问题的特点

碎纸机产生的碎片均为矩形，大小一样，印刷字体，难以利用上述特征进行拼接

?

你有什么思路?

1 2 3

投票 最多可选2项 设置

对于本赛题，以下哪些想法更有潜力？

A

利用碎片大小和颜色、笔迹和墨水等特征

B

利用轮廓信息（边缘形状的几何特征）

C

利用碎片边缘的图像像素信息（特征）

D

本题仅是文本，还可以利用“行”的特征

提交

1 2 3

数学模型

问题分析：整体思路

仅纵切（或仅横切）

提取边缘像素信息，计算两两碎片间的匹配度，从而定义“距离”

纵切 + 横切

分治策略/各个击破：先确定碎片所在列/行（分类），则化成了仅纵切/横切情形

纵切 + 横切 + 双面

类似，更多信息可利用（修改对“距离”的定义）

1 2 3

数学模型

建模：图像 (image) 的矩阵表示

灰度级值（灰度矩阵）
取值 $[0, L-1]$, $L=2^b$
→ $b=1$, 0-1 矩阵

$$f(x, y) = \begin{bmatrix} f(0,0) & f(0,1) & \cdots & f(0,N-1) \\ f(1,0) & f(1,1) & \cdots & f(1,N-1) \\ \vdots & \vdots & \ddots & \vdots \\ f(M-1,0) & f(M-1,1) & \cdots & f(M-1,N-1) \end{bmatrix}$$

$$A = \begin{bmatrix} a_{0,0} & a_{0,1} & \cdots & a_{0,N-1} \\ a_{1,0} & a_{1,1} & \cdots & a_{1,N-1} \\ \vdots & \vdots & \ddots & \vdots \\ a_{M-1,0} & a_{M-1,1} & \cdots & a_{M-1,N-1} \end{bmatrix}$$

1 2 3

数学模型

建模：图像 (image) 的矩阵表示

BMP(Bitmap-File)格式的碎片图像文件

→ 二值化碎片图像

每条碎片由若干像素点组成，取值{0,1}，其中0和1分别表示黑与白（若为彩色/灰度，可更精细处理）
→ 每个碎片，相当于一个 1980*72 的 0-1 矩阵

1 2 3

数学模型

建模：行数确定

碎片文本总行数的识别

确定碎片 i 的行数 n_i ($i=1,2,\dots,19$), 及每行的起始位置

→ 行高 $h = 40$ pixels（像素）

确定所有碎片的最大行数 N , 及每行的起始位置

→ 行数 $N = \max n_i$ （本题为28）

1980*72

1 2 3

数学模型

建模：碎片间距离的定义（仅纵切）

碎片文本行特征的提取

假设所有碎片都是正放、没有倒置的

仙时

表 1 碎片 i 特征数据表

k	1	2	3	...	27	28
n_{kl}	n_{i1l}	n_{i2l}	n_{i3l}	...	n_{i27l}	n_{i28l}
n_{kr}	n_{i1r}	n_{i2r}	n_{i3r}	...	n_{i27r}	n_{i28r}

其中，k 为行号；
 n_{ikl} 为第 i 条碎片第 k 行左侧边缘取值为 0 的像素点的数量；
 n_{ikr} 为第 i 条碎片第 k 行右侧边缘取值为 0 的像素点的数量。

1 2 3

数学模型

碎片间距离的定义（仅纵切）

碎片图像 i, j 的匹配度 M_{ij}

第 k 行：
$$m_{ijk} = \frac{\min(n_{ikr}, n_{jkl})}{\max(n_{ikr}, n_{jkl})}$$

分母为 0 时 M_{ij} 取 1

整体：
$$M_{ij} = \frac{1}{N} \sum_{k=1}^N m_{ijk}$$

距离（费用，成本）： $w_{ij} = 1 - M_{ij}$

图像 i, j

1 2 3

数学模型

有向图模型（仅纵切）

构造有向图（网络） (V, E, W)
 $(|V|=n=20)$

(1) 引入空白碎片 0，计算得到空白碎片与其他碎片的匹配度；

(2) 节点表示碎片，有向线段长度表示费用 $w_{ij} = 1 - M_{ij}$ ，如 ①→② 的费用表示 1 号的碎片右侧边缘与 2 号碎片左侧边缘的费用；

(3) 寻找一条回路遍历所有的节点使得费用达到最小。

1 2 3

数学模型

模型（仅纵切）的求解

该模型实际上是 TSP
(Travelling Salesman Problem)

TSP: 旅行商 / 货郎(担)问题

一名推销员准备前往若干城市推销产品。如何为他/她设计一条最短的旅行路线(从驻地出发，经过每个城市恰好一次，最后返回驻地，即“环游”)？

已有一百多年历史，但属于 NPC (NP-Complete) 问题：

对大规模问题，无“有效”算法

1 2 3

数学模型

什么是“有效”算法？——通俗版

例 构造算法将 n 个自然数从小到大排列起来

算法 输入自然数 $a(1), a(2), \dots, a(n)$.
for ($i=1; i \leq n; i++$)
for ($j=i+1; j \leq n; j++$)
if ($a(i) > a(j)$)
{ $k=a(i); a(i)=a(j); a(j)=k;$ }

基本运算的总次数(最坏情形)： $2n(n-1) = O(n^2)$

比较： $(n-1) + (n-2) + \dots + 1 = n(n-1)/2$
赋值： $3 \{ (n-1) + (n-2) + \dots + 1 \} = 3n(n-1)/2$

即该算法的计算(时间)复杂度为 $2n(n-1) = O(n^2)$

用于衡量算法的优劣

1 2 3

数学模型

什么是“有效”算法？——通俗版

复杂度	近似值			工具提速 10 倍	
n	10	100	1000	10^{12}	10^{13}
$n \log n$	33	664	9966	0.9e11	0.87e12
n^2	100	10^4	10^6	10^6	3.16e6
n^3	1000	10^6	10^9	10^4	2.15e4
$10^8 n^4$	10^{12}	10^{16}	10^{20}	10	18
2^n	1024	1.27e30	1.05e301	40	43
10^n	10^{10}	10^{100}	10^{1000}	12	13
$n^{\log n}$	2079	1.93e13	7.89e29	79	95
$n!$	3628800	10^{158}	4e2567	14	15


1 2 3

数学模型

什么是“有效”算法？---通俗版

有效：计算复杂度可被多项式函数控制
如 $O(n^2)$, $O(n^{100})$, $O(n\log n)$, ...
称为**多项式算法**, 相应的问题称为**多项式问题**

TSP: 完全枚举法可以求得最优解, 但不是有效算法!



$(n-1)!$ 枚举(Tour, 周游或环游)
设计算机每秒进行100亿次枚举, 需
 $30! / 10^{10} > 2.65 \times 10^{22}$ (秒)
即 $2.65 \times 10^{22} / (365 \times 24 \times 60 \times 60)$
假设 $n = 31$ $> 8.4 \times 10^{13}$ (年)

数学模型

什么是“有效”算法？---通俗版

对一个给定的问题, 若**存在**一个求解该问题的多项式时间算法, 则称该问题属于问题集合 **P** (Polynomial)




TSP至今没有找到多项式时间算法, 但与许多问题在求解难度上等价, 属于 **NPC 问题**
但尚未证明其一定不存在多项式时间算法!

NP 是Nondeterministic-Polynomial 的缩写
P = NP? (或者 **P = NPC?**)
TSP是否存在多项式时间算法?
—— 21世纪数学和计算机科学的挑战性问题之一

数学模型

模型 (仅纵切) 的求解



$x_{ij}=1$: 从*i*到*j*
0: 否则

TSP的0-1规划模型
数学上用赋权图 (网络) 描述:
 $G = (V, E, W)$

$$\min \sum_{(i,j) \in E} w_{ij} x_{ij}$$
$$\sum_{(i,j) \in E} x_{ij} = 1 \quad \forall i$$
$$\sum_{(j,i) \in E} x_{ji} = 1 \quad \forall i$$
$$x_{ij} \in \{0,1\}, (i,j) \in E$$

这些约束就足够了吗?

单选题 1分

设置

上述约束条件是否就足够了?

☐ A 足够了, 不需要增加新的约束条件

☐ B 足够了, 但如果增加更多条件, 这个问题难以求解, 所以还需要增加条件


☒ C 不够, 因为满足约束时不能保证一定构成一条环游, 有可能形成多个子环游 (subtour)

☐ D 不够, 因为满足约束时不能保证每个节点只经过一次

提交

数学模型

模型 (仅纵切) 的求解



$x_{ij}=1$: 从*i*到*j*
0: 否则


TSP的0-1规划模型
数学上用赋权图 (网络) 描述:
 $G = (V, E, W)$

$$\min \sum_{(i,j) \in E} w_{ij} x_{ij}$$
$$\sum_{(i,j) \in E} x_{ij} = 1 \quad \forall i$$
$$\sum_{(j,i) \in E} x_{ji} = 1 \quad \forall i$$
$$x_{ij} \in \{0,1\}, (i,j) \in E$$

Only One Circle 防止subtour

数学模型

模型 (仅纵切) 的求解



Only One Circle 这个约束怎么处理?

方法1

$$\sum_{i \in S, j \in S} x_{ij} \leq |S| - 1 \quad (S \subsetneq V, |S| > 1)$$

方法2


$$\sum_{i \in S, j \in V-S} x_{ij} + x_{ji} \geq 2 \quad (S \subsetneq V, |S| > 1)$$

但这样的约束有指数多个!

数学模型

模型（仅纵切）的求解

(n)



Only One Circle 这个约束怎么处理?

方法3

引入变量 u_i 表示经过节点 i 的顺序

$$u_1 = 1,$$
$$2 \leq u_i \leq n \quad \forall i \neq 1,$$
$$u_i - u_j + 1 \leq (n - 1)(1 - x_{ij}) \quad \forall i, j \neq 1$$

Why? $u_j \geq u_i + 1$ when $x_{ij} = 1$

这样的约束最多只有 $O(n^2)$ 个

0-1线性规划 仍是NPC问题

数学模型


模型（仅纵切）的求解

近似求解：贪婪算法
(Greedy Algorithm)

可处理大规模问题

对小规模问题效果较好，
甚至可得到最优解
(完全正确的复原结果)

TSP在印刷电路板设计、机器
翻译等问题中也可应用



数学模型

扩展：纵切 + 横切

分类——如何分组（同行？同列？）



关键仍是距离定义
行信息的作用相对降低，
可考虑边缘向量的内积等
(英文还可利用四线三格特征等)

Tayhblgp

双面（略）

部分优秀论文可参见中国大学生在线，如：
http://dxs.moe.gov.cn/zx/a/qkt_sxjm/131112/1249187.shtml

数学模型

思考：还有什么问题可用TSP建模？

例：机器翻译——一种TSP模型

We designed an algorithm simple enough for the traveling salesman problem.

我们为旅行商问题设计了一个足够简单的算法

我们设计了一个算法简单的足够为旅行商问题

我们、设计了、一个算法、简单的、足够、为、旅行商问题

定义每两个词之间的距离！
→ TSP

数学模型

思考：还有什么问题可用TSP建模？

例：机器翻译——
不是容易的事情！

How are you?
怎么是你?

How old are you?
怎么老是你?



数学模型

参赛论文的一些典型问题

- 只有算法，没有模型(原理)
- 只有程序，没有算法(流程)
- 就事论事，没有一般性
- 没有模型检验（如一般的复原率）
- 东抄西抄，不问背景，也不注明出处
-

数学模型

CUMCM评阅标准

假设的合理性，建模的创造性，

结果的正确性，表述的清晰性。

合理性：关键假设(不欣赏罗列大量无关紧要的假设)；
要对假设的合理性进行解释，正文中引用

创造性：特别欣赏独树一帜、标新立异，但要合理

正确性：不强调与“参考答案”的一致性和结果的精度，
好方法的结果一般比较好；但不一定是最好的

清晰性：摘要应理解为详细摘要，提纲挈领
全文表达严谨、简捷，思路清晰
引用规范(含网络资料)

1 2 3

数学模型

写作中的一些常见问题

数学模型最好**明确、合理、简洁**：

有些论文不给出明确的模型，只是根据赛题的情况，
实际上是用“凑”的方法给出结果，虽然结果大致是对的，
没有一般性，不是数学建模的正确思路。

有的论文过于简单，该交代的内容省略了，难以看懂

有的队罗列一系列假设或模型，又不作比较、评价，
希望碰上“参考答案”或“评阅思路”，弄巧成拙

参考文献应在正文中引用：有的论文参考文献不全，
或引用他人结果不作交代(包括引用网上资料)

1 2 3

数学模型

两点容易忽视之处

模型的检验

你的模型为什么是有效的？

模型的敏感性分析(Sensitivity analysis)

模型的优缺点

优点(Strength)

突出特点；实事求是
(不要夸大)

不足(Weakness)

抓住本质；一针见血
(少说无关痛痒的话)

1 2 3

数学模型

CUMCM评阅标准

假设的合理性，建模的创造性，

结果的正确性，表述的清晰性。

- 模型完整明确
- 深入思考/分析
- 模型/算法创新
- 表达规范严谨
- 软件使用恰当
- 严禁作弊抄袭

目的：提高建模能力 (Ability vs Competency)

1 2 3

多选题 2分

设置

关于数学建模竞赛的论文写作，以下说法正确的是

- ☐ A 如果竞赛规则中对论文长度没有严格限制，
那么应该尽量多写、以便增加论文篇幅
- ☒ B 不仅要给出参考文献，而且应在正文引用处
标注引用
- ☐ C 为了防止与已有文献雷同，最好先到网上利用
第三方的“查重”服务、检测论文的相似度
- ☒ D 利用网上资料，也应该给出网址和引用
- ☐ E 尽量多写几个模型，增加“对上”出题人给出
的答案的概率

提交

1 2 3

数学模型

【预告】足球射门/防守策略

- **目标：进球(概率)**
 - 防守方：最小化
 - 罚球方：最大化
- **考虑哪些影响进球因素？**
- **关键决策**
 - 罚球方：哪个方向踢？
 - 防守方：选哪个位置？
- **方向、位置**
 - 空间维数？
 - 3, 2, 1?
 - 离散(有限选择)
vs 连续(无限选择)



1 2 3